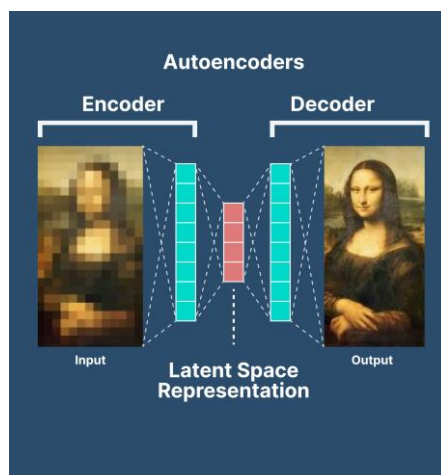


Generative Modeling

Auto-Encoders

Um encoder é responsável por transformar um input para sua característica principal, enquanto o decoder serve para retornar essa característica para o objeto inicial.

Por exemplo, considere uma foto de um sapato, o encoder é responsável por retornar as características presentes nessa imagem que a transforma para um sapato, já o decoder utiliza destes pontos destacados para retornar um sapato completo.



Uma das aplicações de encoder é a utilização da Transpose convolution, responsável por transformar uma imagem de input baixo para uma imagem maior. Essa aplicação pode ir além de apenas utilização com imagens.

Variational Auto-Encoders (VAE)


Semelhante ao auto-encoder, o VAE pode gerar novos dados de forma controlada, porque aprendem uma distribuição de probabilidades para as representações longas, permitindo assim criar variações dos inputs.

Para o VAE funcionar precisamos resolver um dos problemas de sua construção, a distribuição de probabilidade Z não pode ser diferenciado. O truque utilizado é converter as amostras aleatórias para uma fórmula determinística.

Podemos considerar:

$$Z = \mu + \sigma * \epsilon$$

Onde ϵ é a variável aleatória, removendo assim o problema da amostragem e devolvendo um gráfico totalmente conectado.



Generative Adversarial Networks (GAN's)

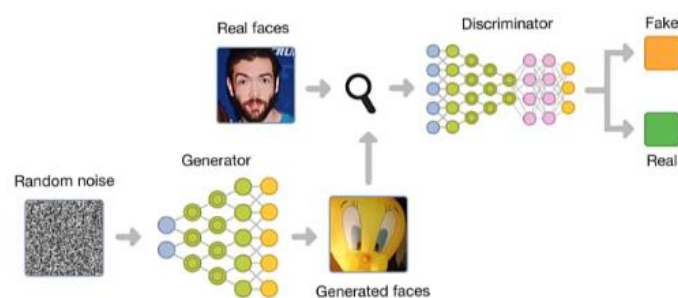
Essa rede é a responsável pela criação de deepfakes, o uso da inteligência artificial para gerar rostos falsos, trocar de rostos e até envelhecer uma pessoa.

Mesmo considerando um tema complicado e com possíveis malícias resultantes, a criação desta ideia possui como base algumas intenções boas, o curso aponta algumas delas como gerar dados sintéticos em casos de dificuldade, detecção de anomalias e até carros que dirigem sozinho.

O núcleo deste sistema é formado por dois principais mecanismos, sendo eles o generator e o discriminator.

- O generator é responsável por pegar um input baseado em noises aleatórios e passar por um tratamento na qual resulta em uma imagem desejada.
- O discriminator analisa a imagem gerada e uma real para identificar pontos e características que resultam na diferenciação entre ambas as imagens, resultando assim em qual é verdadeira e qual é falsa.

Em teoria, quando o discriminator não for capaz de identificar a imagem real da gerada, estaremos enfrentando um grande problema.



Um possível problema enfrentado ao utilizar do modelo GAN é ao considerar modelos com diferentes parâmetros, alguns mais difíceis que outros, o modelo vai se adaptar melhor para os objetos simples. O curso utiliza o modelo Fashion MNIST como exemplo, o modelo priorizou gerar camisetas e calças ao invés de sapatos, considerando a maior complexidade dele.

Atividades

Na primeira parte deste card, é tratado de modelos generativos para a criação de imagens, o curso passa por alguns exemplos escritos e demonstra a aplicação e utilização de modelos com essa função.

Os modelos apresentados foram os de Variational Auto-Encoders (VAE) e Generative Adversarial Networks (GAN's).

- VAE: Um modelo mais simples na qual aprende a comprimir dados e em seguida gerar novos dados a partir disso.
- GAN's: Envolve dois modelos competindo entre si, um gerador que tenta criar dados falsos e um discriminador que tenta descobrir se esses dados são reais ou não.

Já na segunda parte do card, foi tratado sobre como criar um modelo generativo de texto do zero, utilizando formas públicas conhecidas de como o ChatGPT foi gerado, diminuindo bastante o escopo do projeto para servir um fim educativo.

Abaixo está um exemplo do código presente no vídeo, porém modificado para aprender com o .txt do Harry Potter e a Câmara Secreta.

```
- A Segre e em  
o foi um sob corribido da fencar a vegens que você?  
Devem para os oros porque mas um grants carro, que sem cuima iderva; a mão você-la  
de Lockhart - disse Rony - inventou a Profª. Sua que você engro Harry de  
Lockhart se acostava tertiva de rorte Secretudas. Harry e engro
```

Ainda apontado no vídeo, o modelo apenas é capaz de juntar palavras e frases considerando os seus caracteres passados, para transformar no modelo inteligente parecido com o GPT, seria necessário uma parte extra de treinamento para criar um contexto e uma resposta em diversos temas, uma espécie de guia para o modelo.

Atividade Criada

A atividade criada consiste em fazer um modelo generativo de imagens baseado em GAN's, utilizando dos conceitos aprendidos durante o curso, o trabalho trata desde o tratamento dos dados, criação e customização do generator/discriminator até a geração de dados finais.

Utilizando da base de imagens MNIST, o trabalho não teve uma complexidade grande e foi possível visualizar bons resultados, mesmo considerando um pequeno número de

iterações visto que não possuo uma placa de vídeo da Nvidia (Aprox. 2h de duração com 40 epochs).



Conclusão

O estudo de modelos generativos como Auto-Encoders, Variational Auto-Encoders (VAE) e Generative Adversarial Networks (GANs) mostrou como essas técnicas são poderosas para gerar novos dados, seja em forma de imagens ou textos. Aprendemos como os Auto-Encoders conseguem comprimir e reconstruir dados, enquanto os VAEs introduzem controle sobre as variações dos dados gerados. As GANs, por sua vez, destacam-se pela interação entre gerador e discriminador, proporcionando resultados impressionantes, como deepfakes, apesar dos desafios em equilibrar esses modelos.